

דוח פרוייקט בלמידת מכונה - שיראל עמר ו- שרה דרעי

1. תיאור הדאטה המעובד ויצירת ה-features:

בתחילת הפרויקט קיבלנו קובץ נתונים הכולל 133,884 סרטים ו-13 עמודות:

tconst	primaryTitle	startYear	genres	lead_actors_ids	runtimeMinutes	averageRating	Language	Country	budget	BoxOffice	plot
מזהה סרט	שם הסרט	שנת יציאת הסרט	ז'אנר	מזהה של השחקנים הראשיים	משך הסרט בדקות	ציון ממוצע של הסרט בIMDB	שפת הסרט	מדינת הסרט	תקציב הסרט	הכנסות הסרט	עלילת הסרט

מטרת הפרויקט היא לבנות מודלים המנבאים את הדירוג הממוצע של סרט לפני יציאתו לאקרנים. לכן, משתנה המטרה שלנו הוא averageRating.

מודל Elastic Net הוא דרישה מהמרצה, ובמודל השני בחרנו ב־Random Forest ולא ב־Decision Tree, משום שהוא משלב כמה עצים, יוצר תחזיות יציבות ומדויקות יותר, ומאפשר לזהות קשרים מורכבים יותר בדאטה.

כדי להימנע מ-**data leakage**, לא השתמשנו בעמודות הבאות כפיצ'רים :

- averageRating** : הוא משתנה המטרה שאותו אנו מנסים לחזות וזו נתון שזמינה רק אחרי יציאתו של הסרט.
- numVotes** : מספר ההצבעות מצטבר לאחר יציאת הסרט.
- BoxOffice** : הכנסות הסרט ידועות רק לאחר יציאתו.

לאחר קבלת הדאטה, העשרנו אותו באמצעות קובץ title.crew.tsv.gz של IMDb. קובץ זה כולל את מזהי הבמאים של כל סרט. חיברנו את הקובץ לדאטה המקורי לפי העמודה tconst, וכך הוספנו את העמודה directors.

בהמשך ביצענו מספר בדיקות מקדימות כדי להבין את מבנה הדאטה ולהחליט כיצד להשתמש בכל עמודה. בין היתר, בדקנו את מספר הערכים החסרים בכל עמודה, את סוגי הערכים ואת הפורמטים השונים הקיימים בעמודות טקסט.

לאחר הבדיקות החלטנו לא להשתמש ישירות בעמודות הבאות במודל:

- tconst** : מזהה הוא ייחודי לכל סרט, לא יהיה השפעה על ציון הממוצע.
- primaryTitle** : גם ייחודי לכל סרט, לא יהיה השפעה על ציון הממוצע.
- budget** : עמודת budget לא נכללה במודל משום שכמעט 90% מהערכים היו חסרים והמטבעות לא היו אחידים. לכן גם לאחר המרה למטבע אחד, המידע לא היה מספיק אמין ושימושי.
- plot** : ייחודי עבור כל סרט, לא היה מוסיף למודל בעינינו.
- Language** : רוב הערכים חופפים לעמודת Country, ולכן בחרנו להשתמש באחת מהעמודות ולא בשתיהן.
- לעומת זאת, השתמשנו בעמודות הבאות לצורך יצירת features חדשים: startYear, genres, runtimeMinutes, lead_actors_ids, Country, directors

לאחר הפעלת הפונקציה prepare_data, התקבלו הפיצ'רים הבאים לשימוש במודלים:

features	runtimeMinutes	num_directors	genre_<name>	country_group	decade
about the feature	אורך הסרט בדקות	מספר הבמאים של הסרט	עמודה בינארית עבור כל אחד מהז'אנרים הנפוצים. הערך הוא 1 אם הסרט שייך לז'אנר ו-0 אחרת. אם הסרט הוא לא חלק מהז'אנרים הנפוצים הוא יקבל ערך 1 תחת genre_Other	חלוקה של מדינת המקור לקבוצות מרכזיות ול-Other	עשור יציאת הסרט
why we use it ?	אורך הסרט עשוי להשפיע על הדירוג ולהיות קשור לסוג הסרט ולמבנה שלו.	כדי לבדוק האם סרטים עם כמה במאים מתנהגים אחרת מסרטים עם במאי אחד.	ז'אנר הסרט עשוי להשפיע על הדירוג. יצירת עמודות בינאריות מאפשרת לסרט להשתייך לכמה ז'אנרים במקביל.	כדי לצמצם את מספר הקטגוריות ולשמור מידע כללי על מדינת המקור גם כאשר קיימות מדינות נדירות.	חלוקה לעשורים מאפשרת לזהות מגמות כלליות לאורך זמן ומפחיתה רעש שנובע מהבדלים קטנים בין שנים בודדות.

features	num_genres	num_lead_actors	directors_x_genres	country_known	age_x_country_known
about the feature	מספר הז'אנרים המשויכים לסרט	מספר השחקנים המובילים של הסרט	פיצ'ר מורכב המחושב כמכפלה של מספר הבמאים ומספר הז'אנרים num_directors × num_genres	הערך הוא 1 אם מדינת המקור ידועה ו-0 אם המידע חסר	פיצ'ר מורכב המחושב כמכפלה של גיל הסרט והאינדיקציה האם מדינת המקור ידועה film_age × country_known
formula for	כדי לבדוק האם סרטים המשלבים	כדי לבדוק האם מבנה הקאסט ומספר	השתמשנו בו כדי לבדוק האם סרט	מכיוון שחסר מידע על המדינה	כדי לבדוק האם השפעת גיל הסרט על הדירוג משתנה

complex features	כמה ז'אנרים מתנהגים אחרת מסרטים השייכים לז'אנר אחד בלבד.	השחקנים המרכזיים משפיעים על הדירוג.	שמשלב כמה ז'אנרים וכמה במאים עשוי לפנות לקהל רחב יותר ובהתאם לקבל דירוג גבוה יותר	עשוי להיות קשור לסוג הסרט ולהשפיע על איכות התחזית.	כאשר מידע על מדינת המקור קיים או חסר.
------------------	--	-------------------------------------	---	--	---------------------------------------

2. תיאור פונקציית prepare_data:

הפונקציה מקבלת דאטה סט גולמי ומחזירה דאטה פריים מעובד הכולל רק את הפיצ'רים הדרושים למודל. לפני הפונקציה מוגדרת פונקציית עזר:

- load_crew : טוענת את קובץ הבמאים של IMDb. השימוש ב-lru_cache מאפשר לטעון את הקובץ פעם אחת בלבד ולמנוע הורדה חוזרת בכל קריאה ל-prepare_data.

בתוך prepare_data מבוצעים השלבים הבאים:

1. יצירת עותק של הדאטה באמצעות df.copy(), כדי לא לשנות את הדאטה פריים המקורי.
2. build_country_pattern : יוצרת רשימת שמות מדינות ווריאציות אפשריות, כדי לזהות מדינות גם כאשר קיימים פורמטים לא אחידים.
3. main_genres : רשימה של 10 הז'אנרים הנפוצים ביותר שנבחרו על בסיס ניתוח מקדים של הדאטה.
4. הפעלת הפונקציית חיצונית כדי להביא מ-IMDb crew.
5. חיבור נתוני הבמאים לדאטה לפי tconst, יצירת רשימת במאים לכל סרט וחישוב מספר במאים עבור כל סרט : num_directors
6. ניקוי עמודת genres: הסרת סוגריים, גרשיים ורווחים מיותרים. לאחר מכן נוצרת עמודה בינארית לכל אחד מהז'אנרים הנפוצים, וכן genre_Other עבור סרטים הכוללים לפחות ז'אנר אחד שהוא פחות נפוץ.
7. ניקוי עמודת Country: החלפת Not Found בערך חסר, זיהוי המדינה הראשונה המופיעה בטקסט ואיחוד וריאציות כמו United States, USA ו-United States of America.
8. יצירת features המבוססים על המדינה:
 - country_group : חלוקה למדינות מרכזיות ול-Other.
 - country_known : האם מדינת המקור ידועה.
 - startYear : המרה לערך נומרי והפיכת ערכים לא תקינים או שנים לאחר 2025 לערכים חסרים מכיוון שיכולים להיות סרטים מ-2026 שעוד לא יצאו. לא נמחקות שורות, כדי לאפשר חיזוי גם על דאטה חיצונית.
9. יצירת features נוספים:
 - decade : עשור יציאת הסרט. חלוקה לעשורים מאפשרת לזהות מגמות כלליות לאורך זמן ומפחיתה רעש שנובע מהבדלים קטנים בין שנים בודדות
 - num_genres : מספר הז'אנרים של הסרט.
 - num_lead_actors : מספר השחקנים המובילים.
 - directors_x_genres : מכפלת מספר הבמאים במספר הז'אנרים.
 - age_x_country_known : מכפלת גיל הסרט באינדיקציה האם המדינה ידועה.
10. הסרת עמודות שאינן משמשות את המודל, כולל עמודות שיוצרות data leakage: averageRating, numVotes ו-BoxOffice.

השלמת ערכים חסרים, scaling ו-encoding אינם מתבצעים בתוך prepare_data, אלא בתוך ה-pipeline. כך, במהלך cross-validation, כל פעולה נלמדת רק על fold האימון ונמנע data leakage.

3. השוואת המודלים באמצעות 10-fold Cross-Validation

הערכת הביצועים בוצעה באמצעות 10-fold cross-validation. בכל איטרציה המודל התאמן על תשעה חלקים מהדאטה ונבדק על החלק הנותר. עבור כל מדד חישוב את הממוצע ואת סטיית התקן לאורך עשרת ה-folds.

ככל שהערכים של RMSE ו-MAE נמוכים יותר, כך השגיאה של המודל קטנה יותר. לעומת זאת, ככל שהערך של R^2 גבוה יותר, כך המודל מסביר חלק גדול יותר מהשונות בדירוגים.

MODEL	MAE	RMSE	R^2
-------	-----	------	-------

Elastic Net	0.873 ± 0.036	1.137 ± 0.047	0.222 ± 0.021
Random Forest	0.849 ± 0.040	1.114 ± 0.052	0.254 ± 0.027

לפי שלושת המדדים ניתן לראות ש-Random Forest הציג ביצועים טובים יותר מ-Elastic Net.

במהלך tuning של Random Forest, הפרמטרים הטובים ביותר שנבחרו היו:

MODEL	n_estimators	max_depth	min_samples_leaf
Random Forest	200	20	10

n_estimators: מספר העצים שנבנים "ביער". מספר גבוה יותר מאפשר תחזיות יציבות יותר.

max_depth: העומק המקסימלי של כל עץ. עומק גדול יותר מאפשר לזהות קשרים מורכבים יותר אבל עלול להגדיל את הסיכון ל-overfitting.

min_samples_leaf: מספר הסרטים המינימלי הנדרש בכל עלה סופי של העץ. ערך גבוה יותר מונע יצירת כללים המבוססים על מספר קטן מדי של סרטים ומצמצם את הסיכון ל-overfitting.

MODEL	alpha	l1_ratio
Elastic Net	0.01	0.1

alpha = 0.01: עוצמת הרגולריזציה שנבחרה למודל. הוא ערך הנמוך באפשרויות, ולכן המודל שומר על רוב המידע ומקטין את המקדמים בצורה מתונה בלבד.

l1_ratio = 0.1: היחס בין Lasso ל-Ridge שנבחר למודל. ערך זה קרוב יותר ל-0, ולכן המודל מבוסס בעיקר על Ridge, הוא מקטין את המקדמים אבל בדרך כלל לא מאפס לחלוטין מספר גדול של פיצ'רים.

4. חשיבות הפיצ'רים במודל

בחרנו את הפיצ'רים הבאים ונסביר את החשיבות של כל אחד מהם ואת משמעותם:

decade העשור שבו הסרט יצא: בחרנו לחלק את שנות היציאה של הסרטים לעשורים (כמו שנות ה-80 או שנות ה-2010). עשינו את זה כי עולם הקולנוע משתנה מאוד עם השנים, והמשתנה הזה עוזר למודל להבין את תקופת הזמן שבה הסרט הופק.

country_known האם נתון המדינה קיים: בחרנו לבדוק אם המדינה של הסרט רשומה או חסרה (0 או 1).

country_group קבוצת מדינה: בחרנו לבודד את 7 המדינות המובילות שממש הופקו רוב הסרטים (כמו ארה"ב והודו) ולשים את השאר בקבוצה כללית. עשינו את זה כי לתעשיות ענקיות יש בדרך כלל תקציבים גדולים, הפצה רחבה והמון מצביעים, וזה עלול להשפיע על גובה ציוני הסרטים במערכת.

num_directors, num_genres, num_lead_actors מספר הבמאים, הז'אנרים והשחקנים הראשיים: בחרנו לספור באופן כמותי כמה במאים, כמה ז'אנרים וכמה שחקנים ראשיים רשומים לכל סרט במערכת. המשתנים האלו נותנים למודל מדד בסיסי לגבי גודל ומבנה צוות ההפקה של הסרט.

genre - genre_Other: עמודות ז'אנר ספציפיות וז'אנר אחר: בחרנו ליצור עמודה נפרדת (0 או 1) עבור כל אחד מהז'אנרים הכי נפוצים בדאטה, ועמודה כללית לז'אנרים נדירים יותר. זה מאפשר למודל ללמוד ישירות איך השתייכות לז'אנר ספציפי (כמו דוקומנטרי או אימה) משפיעה על גובה הציון המנובא.

directors_x_genres: מכפלת מספר הבמאים במספר הז'אנרים בחרנו להכפיל את מספר הבמאים במספר הז'אנרים של הסרט. המספר שיוצא מראה על המורכבות של הסרט למשל, אם יש הרבה במאים והרבה ז'אנרים במקביל.

age_x_country_known: מכפלת גיל הסרט בקיום נתון המדינה בחרנו להכפיל את גיל הסרט בשנים בנתון שאומר אם המדינה ידועה. רצינו לבדוק את השילוב ביניהם, כדי שהמודל יבין אם סרט ישן מאוד שאין עליו מידע לגבי המדינה שלו, מתנהג מבחינת הציונים אחרת מסרט ישן שהמדינה שלו מוכרת וידועה.

5.2 ניתוח השגיאות של המודל (Error Analysis)

בדקנו כמה סרטים ספציפיים כדי להבין למה המודל טעה לגביהם:

1. **Justin Bieber: Always Believing** : הציון האמיתי שלו הוא 1.0 אבל המודל ניחש 7.12. המודל לא יודע מי זה ג'סטין ביבר ואיך הקהל הגיב אליו. המודל רק ראה שמדובר בסרט דוקומנטרי, ובגלל סרטים דוקומנטריים בדרך כלל מקבלים ציונים גבוהים, הוא נתן לו אוטומטית ציון גבוה.
2. **Zoo School** : הציון האמיתי הוא 1.1 אבל המודל ניחש 7.25. הסרט הזה הוא אנימציה משנת 2019. המודל לא יודע אם הסרט מעניין או עשוי טוב, הוא פשוט הלך לפי הכלל שסרט אנימציה מהשנים האחרונות שווה ציון גבוה.
3. **Bukunja Tekunja Mitti: The Cannibals**: הציון האמיתי הוא 9.1 והמודל ניחש 4.04. זהו סרט אקשן ואימה משנת 2012. המודל נוטה לתת ציונים נמוכים לז'אנרים אלו, ובהיעדר המידע הגיאוגרפי ביצע חיזוי-חסר משמעותי.
4. **Son-nim-1 Cheo-beon-jjae I-ya-gi**: הציון האמיתי הוא 9.1 והמודל ניחש 4.30. זהו סרט אימה ומתח משנת 2011. המודל למד שסרטי אימה ומתח מקבלים לרוב ציונים נמוכים, ולכן הוריד לו את הציון ופספס סרט שקיבל דירוג גבוה מהקהל.
5. **Il Santo Veleno**: הציון האמיתי הוא 9.4 והמודל ניחש 4.60. זהו סרט מתח משנת 2023 ללא נתון מדינה רשום. המודל נוטה לחזות ציונים נמוכים לסרטי מתח, ובשילוב עם המידע החסר חזה ציון נמוך מדי.

ב. דפוסים משותפים שגילינו:

כשהסתכלנו על כל קבוצת טעויות, מצאנו מאפיינים ברורים:

- **בסרטים שקיבלו ציון גבוה מדי** : ראינו שסרטים דוקומנטריים שולטים פה **9 מתוך 10 סרטים הם דוקומנטריים**. חוץ מזה, רובם סרטים חדשים משנות ה-2010 או ה-2020 (8 מתוך 10). המודל פשוט לא מצליח לזהות סרטים דוקומנטריים חדשים שהם פחות טובים.
- **בסרטים שקיבלו ציון נמוך מדי** : ראינו שזה לרוב סרטים חדשים שאין להם נתון מדינה במערכת. הטעויות האלו קורות כמעט רק בסרטי אימה ומתח. המודל אוטומטית מוריד להם את הציון ומפספס את הסרטים הטובים באמת בז'אנרים האלו.

5.3 השוואה בין המודלים

השוונו את מקרי הקיצון של שני המודלים (Elastic Net ו-Random Forest) וגילינו את הדברים הבאים:

- **טעויות דומות ברוב הזמן**: ראינו ש-11 מתוך 20 הטעויות הכי גדולות משותפות לשני המודלים. זה מראה ששני המודלים מתקשים עם אותם סרטים חריגים.
- **גודל הטעות דומה**: ברוב המקרים, ההבדל בטעות בין המודלים קרוב לאפס. כשאחד טועה בהרבה, גם השני טועה הרבה ולא מצליח יותר מהמודל השני.
- **יוצאים מן הכלל**: מודל Elastic Net הצליח יותר בסרטים "Halloween Deluxe" ו-"Zoo School". מודל Random Forest הצליח יותר בסרטים "At the Back of the Screen" ו-"Zen Comedy".
- **שורה תחתונה**: שני המודלים עושים טעויות מאותו סוג, שניהם נותנים ציון גבוה מדי לסרטים דוקומנטריים לא טובים, וציון נמוך לסרטי אימה ומתח טובים.

[גרף השוואה בנספח 1](#)

5.4 הצעות לשיפור

על סמך ניתוח השגיאות שביצענו, אנחנו מציעות להוסיף בעתיד שלושה פיצ'רים חדשים כדי לשפר את דיוק המודל:

1. הקשר בין אורך הסרט לז'אנר

ראינו שמשך הסרט הוא משתנה משפיע במודל. עם זאת, אורך חריג (ארוך מדי או קצר מדי) ביחס לז'אנר משנה לחלוטין את דעת הקהל. חישוב המרחק מהאורך הממוצע של הז'אנר יעזור למודל לזהות חריגות ולצפות ציונים קיצוניים יותר.

2. מדד הפרסום של השחקנים

אנחנו מציעות להוסיף מדד מספרי שמייצג כמה השחקן פופולרי לפני שהסרט יצא. אפשר לבסס את הציון הזה על כמות הסרטים הקודמים שהשחקנים האלו עשו. משתנה זה יסייע למודל להבין ולהסביר ציונים חריגים שנובעים מקהל יעד מסוים, בעיקר עבור סרטים שקשורים לאישים מפורסמים מאוד או לקהילות מעריצים גדולות.

3. הצלחה קודמת של הבמאי

אנחנו מציעות להוסיף פיצ'ר שיחשב את ממוצע הציונים של הסרטים הקודמים של הבמאי. החישוב יתבצע בצורה מבוקרת ויכלול אך ורק סרטים שיצאו לפני שנת היציאה של הסרט הנוכחי. שיטה זו תאפשר למודל להעריך מראש את איכות ההפקה הצפויה של הסרט על סמך הבמאי, מבלי לייצר Data Leakage. הפיצ'ר יפחית את טעויות החיזוי עבור סרטים חדשים, שהז'אנר הכללי שלהם לבדו לא מספיק כדי להסביר את הציון האמיתי שלהם.

6. ניתוח הוגנות

בפרק זה בדקנו האם המודל שלנו מדויק באותה מידה על קבוצות שונות של סרטים, או שיש קבוצות שהוא טועה יותר. נזכיר ששגיאת המודל הממוצעת על כל הנתונים היא: $RMSE = 1.114$ ו- $MAE = 0.849$.

6.1 החלוקה לקבוצות ו6.2 הצגה חזותית

כדי לבצע את הניתוח, בחרנו לחלק את הנתונים לשני חתכים שונים ולחשב עבור כל קבוצה את מדדי השגיאה:

- א. לפי ז'אנר: בחרנו לבדוק את דרמה, קומדיה, רומנטיקה, אקשן ודוקומנטרי. ראינו שסרטי אקשן הם החלק הכי פחות מדויק של המודל (השגיאה בהם גבוהה בכ-10% מהממוצע). לעומת זאת, סרטים דוקומנטריים מציגים בממוצע את השגיאה הנמוכה ביותר (כ-10.5% מתחת לממוצע). גרף לוקת לקבוצות ז'אנר: [נספח 2](#)
- ב. לפי עשור יציאה (Decade): בחרנו לחבר את נתוני העשורים לטבלת השגיאות, לקבץ את הסרטים לפי תקופות ולסנן עשורים קטנים עם פחות מ-100 סרטים כדי לשמור על יציבות סטטיסטית. לאחר מכן, סידרנו את העשורים לפי סדר כרונולוגי וחישבנו את אחוז הסטייה של השגיאה בכל עשור לעומת הממוצע הכללי של המודל. ראינו שביצועי המודל פחות מדויקים בסרטים חדשים, ובמיוחד משנת 2020 והלאה, שם שגיאת החיזוי עולה בכ-5% מעל הממוצע. הבנו שסרטים ישנים קלים יותר לניבוי מכיוון שרק הקלאסיקות המוצלחות באמת שרדו ותועדו במערכת לאורך השנים. גרף לוקת לקבוצות עשור: [נספח 3](#)

6.3 דיון ומסקנות

- ראינו שסרטי אקשן/אימה הם הנקודה החלשה ביותר של המודל. בנוסף, גילינו עוד בעיה: למרות שז'אנר דוקומנטרי נראה מדויק בממוצע, הוא מייצר את טעויות של החריגים שלנו. $overfitting$. סרטי אימה ומתח סובלים מבעיה הפוכה $underfitting$.
- המודל מסביר רק 25.4% מהשונות בציונים ($R^2=0.254$), ולכן הוא לא מספיק אמין לשימוש מסחרי ללא בידקות נוספות. היינו נזהרות במיוחד מחיזויים עבור סרטים דוקומנטריים הקשורים לכוכבי פופ, סרטי אימה ומתח יוצאי דופן. סרטים שחסר בהם מידע על מדינת המקור, וסרטים בעלי ציונים קיצוניים מאוד (מתחת ל-3 או מעל 8.5) המודל נוטה לחזות ערכים קרובים יותר לממוצע ולכן עלול להחמיץ מקרים חריגים.

הקשר בין מידע חסר להטיה (Bias): בניתוח ה-outliers ראינו שבחלק גדול מהמקרים מידע על מדינת המקור היה חסר ($country_known = 0$). כאשר מידע זה אינו זמין, המודל נאלץ להסתמך על features אחרים, ולכן ייתכן שהתחזית פחות מדויקת. עם זאת, לא ניתן להסיק בוודאות שהחסר במידע הוא הסיבה הישירה לשגיאות, אלא שמדובר בגורם שעשוי לתרום להן

Data Leakage Prevention

כשבנינו את הפרויקט, אחת המשימות הכי חשובות שלנו הייתה לוודא שאין Data Leakage. רצינו שהמודל שלנו ינבא את ציון הסרט רק על סמך נתונים שידועים לפני שהסרט יוצא לאקרנים, בדיוק כמו בעולם האמיתי. כדי להשיג את זה, ביצענו שני צעדים מרכזיים בתהליך העבודה:

1. מחיקת משתנים מהעתיד:

הורדנו מסט הנתונים של המודל את העמודות הבאות:

- **averageRating** : כמובן שמחקנו אותו מהפיצ'רים, כי זה משתנה המטרה (y) שאותו המודל מנסה לנחש.
- **BoxOffice-i numVotes** : מחקנו את שתי העמודות האלו כי הנתונים האלו נאספים רק אחרי שהסרט כבר יצא לקולנוע והם משקפים ישירות את ההצלחה שלו. אם היינו משאירות אותן, המודל היה מקבל "רמזים מהעתיד". זה היה מעלה את הדיוק של המודל בזמן הלימוד בצורה מלאכותית, אבל המודל היה נכשל על סרטים חדשים שעוד לא יצאו.
- בחרנו להשתמש אך ורק בסרטים שיצאו עד שנת 2025 והפכנו סרטים משנת 2026 כערך NaN. עשינו את זה כי לא כל סרט משנת 2026 יצא עדיין לקולנוע ורצינו ליהות בטוחים שאין לנו leakage כלשהו. החלטה זו מונעת מהמודל להתאמן על סרטים "עתידיים" שאי אפשר באמת לחזות כרגע.

2. שימוש ב-Pipeline: את כל הפעולות של הכנת הנתונים כמו השלמת ערכים חסרים SimpleImputer ונרמול המספרים StandardScaler בחרנו להכניס לתוך Pipeline. כשמריצים בדיקה למודל ב Cross-Validation, הנתונים מתחלקים שוב ושוב לסט אימון וסט בדיקה. ה-Pipeline מבטיח שכל החישובים כמו מציאת הממוצע או החציון כדי למלא ערכים חסרים יתבצעו רק על סמך נתוני האימון של אותו השלב. זה מונע מצב שבו מידע מסט הבדיקה "יזלוג" וישפיע על המודל בזמן שהוא לומד.

7. מסקנות, מגבלות והצעות להמשך

א. מסקנות מהעבודה

בפרויקט הזה בדקנו שני מודלים שונים כדי לנחש ציון של סרטים ב-IMDb: מודל ליניארי (Elastic Net) ומודל מבוסס עצי החלטה (Random Forest). לאחר שהרצנו בדיקות בשיטת Cross-Validation, ראינו שמודל ה-Random Forest נותן את התוצאות הטובות ביותר. המודל השיג מדד שגיאה RMSE של 1.114 וכושר הסבר (R^2) של 0.254. במהלך העבודה הבנו שמשך הסרט בדקות והשתייכות לז'אנרים מסוימים (במיוחד דוקומנטרי, אימה ודרמה) הם המשתנים שהכי משפיעים על הניחוש של המודל.

ב. מגבלות המודל והדאטה

תוך כדי ניתוח התוצאות והשגיאות, ראינו שלמודל שלנו יש שלוש מגבלות מרכזיות:

1. **כושר הסבר נמוך ($R^2=0.254$):** המודל שלנו מצליח להסביר רק כ-25% מהשונות בציונים של הסרטים. הבנו שציון של סרט הוא דבר מורכב מאוד, מושפע מגורמים רבים שלא מופיעים בדאטה. כגון טעם של הבן אדם או לפי התרבות שלו, ולכן קשה מאוד לנחש ציון במדויק רק לפי נתונים טכניים.
2. **מחסור במידע כספי ופופולריות:** כדי למנוע זליגת מידע מהעתיד ומאחר שהיו מעל 87% ערכים חסרים בעמודות התקציב, נאלצנו למחוק את המשתנים האלו. המחיר של ההחלטה הזו הוא שהמודל למד לנחש ציונים בלי לדעת אם הסרט היה יקר ומושקע או זול וחובבני.
3. **הימשכות למרכז:** המודל למד את הממוצע הכללי של הז'אנרים. בגלל זה המודל נוטה לחזות ציונים הקרובים לממוצע, בדרך כלל סביב 6-7. לכן הוא מתקשה לזהות סרטים חריגים, כמו סרטי אימה מצוינים שקיבלו ציונים גבוהים במיוחד או סרטים דוקומנטריים חלשים שקיבלו ציונים נמוכים מאוד.

ג. הצעות להמשך

כדי לשפר את הדיוק של המודל בעתיד, אנחנו מציעות לבצע שלושה שיפורים:

1. **השלמת מידע של העמודה budget:** חיבור מאגר הנתונים ל-API חיצוני (כמו TMDb או OMDb) להשלמת נתוני התקציב וההכנסות (שנמחקו עקב 87% ערכים חסרים), במטרה להעלות את כושר ההסבר (R^2) של המודל.
2. **מעבר לאלגוריתמים** בחינת מודלים סדרתיים כגון XGBoost, CatBoost, הלוודים ומתקנים את שגיאות העצים הקודמים, במקום בניית עצים במקביל כמקובל ב-Random Forest, כדי להקטין את מדדי השגיאה RMSE ו-MAE.

3. **בניית תתי-מודלים מופרדים (Stratified Modeling)** פיצול מערכת החיזוי למודלים ייעודיים נפרדים לפי החתכים המרכזיים למשל: מודל נפרד לסרטים מארה"ב ומודל נפרד לסרטים משאר העולם, במקום שימוש במודל גלובלי יחיד.

4. **ארכיטקטורה דו-שלבית לטיפול חריג** שילוב של מודל סיווג בשלב הראשון לזיהוי סרטים בעלי פוטנציאל לציונים קיצוניים (מתחת ל-3 או מעל 8.5), והפעלת מודל רגרסיה ייעודי עבורם בשלב השני כדי למנוע את נטיית המודל הנוכחי לנחש ערכים המקורבים לממוצע.


שימוש ב-AI במהלך הפרויקט:

- תיקון שגיאות syntax ושיפור מבנה הקוד.
- מציאת פונקציות שלא הכרנו קודם והבנת אופן השימוש בהן.
- הבנת הסיבות לכך שחלק מהמודלים רצו לאט מאוד או לא הסתיימו, וביצוע התאמות כדי לשפר את זמן הריצה.
- בדיקה של הפונקציה `prepare_data` כדי לוודא שהפעולות שבוצעו אינן יוצרות `data leakage` ושהפונקציה יכולה לפעול גם על שורה בודדת ועל דאטה חיצוני.
- איתור ותיקון שגיאות בקוד, כולל הבנת מקור הבעיה ובדיקת הפתרון
- הבנת תהליך ה-tuning של המודלים לעומק, משמעות ה-hyperparameters והאופן שבו בחירת הערכים משפיעה על הביצועים ועל זמן הריצה.
- שינוי צבע בגרף.

לאחר כל הצעה בדקנו את הקוד באמצעות הרצה מחדש, בחינת הפלטים והשוואת התוצאות לציפיות שלנו.


ניספחים:

ניספח 1:



ניספח 2:

	genre	N	RMSE	MAE	RMSE_difference_%	MAE_difference_%
0	Drama	58460	1.052	0.800	-5.681	-5.773
1	Comedy	33316	1.125	0.862	0.900	1.514
2	Romance	15693	1.015	0.771	-9.001	-9.185
3	Action	13987	1.222	0.948	9.576	11.668
4	Documentary	13014	0.998	0.732	-10.523	-13.788



ספד 3:

	decade	N	RMSE	MAE	RMSE_difference_%	MAE_difference_%
1	1910s	171	0.870	0.651	-22.029	-23.339
2	1920s	785	1.009	0.757	-9.574	-10.885
3	1930s	3121	0.812	0.599	-27.189	-29.419
4	1940s	3292	0.808	0.610	-27.565	-28.175
5	1950s	4602	0.885	0.675	-20.625	-20.519
6	1960s	6208	0.986	0.774	-11.561	-8.853
7	1970s	7969	1.015	0.797	-9.007	-6.134
8	1980s	9631	1.056	0.828	-5.311	-2.524
9	1990s	10213	1.068	0.828	-4.261	-2.516
10	2000s	17555	1.142	0.872	2.401	2.706
11	2010s	33605	1.181	0.895	5.891	5.475
12	2020s	18368	1.246	0.947	11.699	11.537

